Министерство науки и высшего образования РФ
Федеральное государственное автономное образовательное учреждение высшего образования

ТОМСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ СИСТЕМ УПРАВЛЕНИЯ И РАДИОЭЛЕКТРОНИКИ (ТУСУР)
Кафедра автоматизированных систем управления (АСУ)

КОРРЕЛЯЦИОННЫЙ АНАЛИЗ СЛУЧАЙНЫХ ДАННЫХ

Отчёт по лабораторной работе №5 по дисциплине
«Прикладная математическая статистика»

Студент гр. 435-М1
_____ Д.П. Андреев
«__» _____ 2025

Проверил
Профессор каф. АСУ, д.т.н
_____ А.А. Мицель
«__» _____ 2025

Томск 2025

Оглавление

Введение.....3
ХОД РАБОТЫ.....8
Вывод.....10

Введение

Цель работы:

Рассчитать параметрические и непараметрические коэффициенты корреляции.

Задание на лабораторную работу:

5.1. Вычисление параметрических коэффициентов корреляции

1) Сгенерировать средствами пакета EXCEL 5 выборок из 10 значений случайной величины с нормальным законом $N(\mu, \sigma^2)$. Эти 5 выборок будем использовать в качестве независимых признаков $(x_1, x_2, x_3, x_4, x_5)$. Варианты значений параметров μ, σ^2 приведены в приложении 4.

2) Рассчитать зависимый признак

$$y_i = a_0 + a_1 \cdot x_{1i} + a_2 \cdot x_{2i} + a_3 \cdot x_{3i} + a_4 \cdot x_{4i} + a_5 \cdot x_{5i} + \varepsilon_i, \; i = 1,...,10,$$

где $a_0, a_1, ..., a_5$ – параметры (их значения приведены в приложении 4);

ε_i – случайная погрешность с нормальным законом распределения $\varepsilon_i \sim N(0, \sigma_i^2)$, где $\sigma_i = 0,2 \cdot M(y_i / x)$.

Здесь $M(y_i / x) = a_0 + a_1 \cdot x_{1i} + a_2 \cdot x_{2i} + a_3 \cdot x_{3i} + a_4 \cdot x_{4i} + a_5 \cdot x_{5i}$

5.1.1 Парные коэффициенты корреляции

3) Выполнить следующие расчеты:

- вычислить выборочные средние и дисперсии зависимого признака y и независимых признаков x_1, x_2, x_3, x_4, x_5, а также средние значения произведений $\overline{y \cdot x_j}$ по формулам:
- $s_y^2 = \frac{1}{n}\sum_{i=1}^{n} y_i^2 - \left(\frac{1}{n}\sum_{i=1}^{n} y_i\right)^2$; $s_{x_j}^2 = \frac{1}{n}\sum_{i=1}^{n} x_{ij}^2 - \left(\frac{1}{n}\sum_{i=1}^{n} x_{ij}\right)^2$; $j = 1,...,5$;
- $\bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$; $\bar{x}_j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}$; $\overline{y \cdot x_j} = \frac{1}{n}\sum_{i=1}^{n} y_i \cdot x_{ij}$.

  Здесь x_{ij} – i-е значение случайной величины x из j-й выборки.

- вычислить парные коэффициенты корреляции между зависимым признаком y и независимыми признаками x_1, x_2, x_3, x_4, x_5 (коэффициенты корреляции Пирсона) по формулам: $r_{yx_j} = \dfrac{\overline{y \cdot x_j} - \overline{y} \cdot \overline{x}_j}{s_y \cdot s_{x_j}}$.
- скорректировать коэффициент корреляции (так как $n < 15$) по формуле $r^* = r\left(1 + \dfrac{1 - r^2}{2(n-3)}\right)$.
- вычислить t-статистики $t_j = \sqrt{\dfrac{r_{yx_j}^2 (n-2)}{1 - r_{yx_j}^2}}$.

4) Проверить гипотезу о значимости коэффициентов корреляции. Если $t_j > t_{0,95}(n-2=8)$, то коэффициент r_{yx_j} значимый, и, следовательно, связь между y и x_j статистически значима.

5.1.2 Множественный коэффициент корреляции

5) Вычислить парные коэффициенты корреляции между зависимыми признаками $r_{x_i x_j} = \dfrac{\overline{x_i \cdot x_j} - \overline{x}_i \cdot \overline{x}_j}{s_{x_i} \cdot s_{x_j}}$; $j > i$, $i = 1,...,5$, где $\overline{x_i \cdot x_j} = \dfrac{1}{n}\sum_{k=1}^{n} x_{ki} \cdot x_{kj}$; $j > i$; $i = 1,...,5$

Вычислить множественный коэффициент корреляции между результирующим признаком Y и факторными признаками $x_1, x_1, ..., x_5$ по формуле

$$R_{y/x_1,x_2,...,x_m} = \sqrt{1 - \frac{|\rho|}{|\rho_1|}},$$

где $|\rho|$ – определитель матрицы парной корреляции

$$\rho = \begin{pmatrix} 1 & \rho_{yx_1} & \rho_{yx_2} & \rho_{yx_2} & \rho_{yx_4} & \rho_{yx_5} \\ \rho_{x_1 y} & 1 & \rho_{x_1 x_2} & \rho_{x_1 x_3} & \rho_{x_1 x_4} & \rho_{x_1 x_5} \\ \rho_{x_2 y} & \rho_{x_2 x_1} & 1 & \rho_{x_2 x_3} & \rho_{x_2 x_3} & \rho_{x_2 x_5} \\ \rho_{x_3 y} & \rho_{x_3 x_1} & \rho_{x_3 x_2} & 1 & \rho_{x_3 x_4} & \rho_{x_3 x_5} \\ \rho_{x_4 y} & \rho_{x_4 x_1} & \rho_{x_4 x_2} & \rho_{x_4 x_3} & 1 & \rho_{x_4 x_5} \\ \rho_{x_5 y} & \rho_{x_5 x_1} & \rho_{x_5 x_2} & \rho_{x_5 x_3} & \rho_{x_5 x_4} & 1 \end{pmatrix};$$

$|\rho_1|$ – алгебраическое дополнение элемента ρ_{11}.

6) Вычислить скорректированный коэффициент корреляции:

$$R_{y/x_1,x_2,\ldots,x_k} = \sqrt{1-(1-R^2)\frac{n-1}{n-k-1}},$$

7) Вычислить статистику Фишера $F = \dfrac{\frac{1}{2}R^2_{y/x_1,\ldots,x_5}}{\frac{1}{n-6}\left(1-R^2_{y/x_1,\ldots,x_5}\right)}$;

8) Проверить гипотезу о значимости множественного коэффициента корреляции. Если $F > F_{0,95}(\nu_1 = 5, \nu_2 = n-6)$, то множественный коэффициент корреляции считается значимым.

5.2. Вычисление непараметрических коэффициентов корреляции

1) Сгенерировать средствами пакета EXCEL 5 выборок из 10 значений случайной величины с биномиальным законом распределения $B(n, p)$. Эти 5 выборок будем использовать в качестве независимых признаков $(x_1, x_2, x_3, x_4, x_5)$. Варианты значений параметров n, p приведены в приложении 4.

2) Вычислить ранги элементов матрицы X.

5.2.1 Коэффициент ранговой корреляции Спирмена

3) Вычислить:

- величины $d_k^2(i,j) = \left(R_{k,x_i} - R_{k,x_j}\right)^2$; $i \neq j$, $i,j = 1,\ldots,5$; $k = 1,\ldots,10$;
- коэффициенты ранговой корреляции Спирмана $\rho_{x_i/y_j} = 1 - \dfrac{6\sum_{k=1}^{n} d_k^2(i,j)}{n(n^2-1)}$;
- t-статистики $t_{ij} = \left|\rho_{x_i/y_j}\right|\sqrt{\dfrac{n-2}{1-\rho^2_{x_i/y_j}}}$

4) Проверить значимость коэффициентов корреляции. Если $t_{ij} > t_{0,95}(n-2)$, то коэффициент ρ_{x_i/y_j} считается значимым.

5.2.2 Коэффициент ранговой корреляции Кендалла

5) Рассматриваются все комбинации пар столбцов исходной таблицы данных – (1;2), (1;3), (1;4), (1;5), (2;3), (2;4), (2;5), (3;4), (3;5), (4;5). Первый столбец обозначим X, второй – Y.
   - В каждой паре столбцов значения первого столбца X упорядочиваются по возрастанию, а значения второго столбца Y располагаются в порядке, соответствующем значениям X
   - для каждого ранга Y определяется число следующих за ним значений рангов, превышающих его по величине. Суммируя эти числа, определяем величину P (число последовательностей) — меру соответствия последовательностей рангов X и Y (см. пример в лекции);
   - для каждого ранга Y определяется число следующих за ним рангов, меньших его величины. Суммируя величины, получаем величину Q (число инверсий);
   - определяется разность по всем членам ряда $S = P - Q$ и вычисляется τ. Связь между признаками можно признать статистически значимой, если значение коэффициента корреляции $|\tau| > \tau_\alpha = u_\alpha \sqrt{\frac{2(2n+5)}{9n(n-1)}}$.

5.2.3 Коэффициент конкордации (множественный коэффициент ранговой корреляции)

6) Проранжировать столбцы исходной таблицы $\{x_{ji}\}$ (наблюдения) их рангами $\{r_{ji}\}$ не упорядочивая табличные данные.
7) Для каждой j -й строки таблицы вычислить:

   а. сумму рангов $R_j = \sum_{i=1}^{5} r_{ji}$ и квадрат суммы R_j^2;

b. сумму рангов по всей совокупности ранг $R=\sum_{j=1}^{10} R_j$ и $R^2=\sum_{j=1}^{10} R_j^2$;

c. вычислить коэффициент конкордации

$$W=\frac{12\left(R^2-\frac{R^2}{n}\right)}{m^2(n^3-n)},\ m=5,\ n=10.$$

8) Проверить значимость связи между признаками. Если $W>W_\alpha$, где $W_\alpha=\frac{1}{m(n-1)}\chi_\alpha^2(n-1)$, то с вероятностью α корреляция между признаками признается значимой. Если среди последовательностей рангов есть совпадения, то коэффициент конкордации следует вычислять по формуле

$$W=\frac{12\left(R^2-\frac{R^2}{n}\right)}{m^2(n^3-1)-m\sum_{j=1}^{m} T_j},$$

где $T_j=t_j^3-t_j$, t_j – количество совпавших рангов в j-й последовательности. Совпавшим рангам присваиваются средние ранги.

ХОД РАБОТЫ

В первом задание вычисляем параметрические коэффициенты корреляции (рисунок 2.1).

μ	0	a0	a1	a2	a3	a4	a5
σ	0,2	1	2	3	4	5	6

Выборка					M(y|x)	Стандартное отклонение погрешности	Случайная погрешность	Зависимый признак Y	y*x				
0,100969373	0,088001343	0,13215913	-0,114791419	0,015276328	1,51228017	0,091479652	0,050877066	1,56315723	0,157831006	0,13756	0,2065855	-0,17944	0,0238793
-0,132463811	-0,323663699	-0,208997335	0,097439624	-0,171471584	-1,61353944	0,104140381	-0,091663198	-1,7052026	0,225877639	0,551912	0,35638281	-0,16615	0,2923938
0,528918463	-0,481268216	-0,317149897	-0,178903974	0,244475814	-0,0822323	0,000270486	-1,16844E-07	-0,0822324	-0,043494245	0,039576	0,02608	0,014712	-0,0201038
-0,125978659	0,25907184	0,015706064	-0,432657544	0,334501237	1,43180216	0,082002297	0,004875489	1,43667765	-0,180990724	0,372203	0,02256455	-0,62159	0,48057045
0,369297595	0,338086465	0,216266471	-0,19713616	0,201484909	3,84114913	0,590177064	0,069462411	3,91061154	1,444179436	1,322125	0,84573416	-0,77092	0,78792921
0,05472134	0,097611974	-0,030495357	-0,061600758	0,373851435	3,21540199	0,413552399	-0,155286592	3,0601154	0,167453616	0,298704	-0,0933193	-0,18851	1,14402853
-0,01053877	-0,271920726	-0,042115744	0,147235369	0,15484602	1,65995027	0,110217396	0,005762867	1,66571314	-0,017554567	-0,45294	-0,0701527	0,245252	0,25792905
0,140712928	0,063432253	0,05472134	-0,012990768	-0,126669875	0,86563489	0,029972951	-0,014593318	0,85104157	0,119752551	0,053983	0,04657014	-0,01106	-0,1078013
0,116183401	-0,041881094	-0,429075953	0,384558007	0,210136477	2,5740286	0,26502493	-0,382905564	2,19112304	0,254572126	-0,09177	-0,9401582	0,842614	0,46043488
-0,037589643	-0,191979325	0,139441909	-0,026538601	0,154804638	1,7027852	0,115979098	0,194255826	1,89704103	-0,071309096	-0,36419	0,26452702	-0,05034	0,29367075

0,100423222	-0,046450918	-0,046953937	-0,039538622	0,13912354	-	-	-	1,47880455	Среднее
0,03967165	0,063006804	0,039594947	0,04393312	0,02962472	-	-	-	2,2109198	Дисперсия
0,205631774	0,186716171	0,066481391	-0,088543213	0,36129308	-	-	-	-	Ср. произведения

0,192887044	0,684312193	0,459375343	-0,096493672	0,607819591	Коэффициенты корреляции Пирсона
0,206152087	0,710302215	0,485263581	-0,103321902	0,635195583	Скорректировнный коэффициент корреляции
0,556008244	2,654355402	1,462787522	0,274204869	2,165000904	t-статистика
				2,306004135	Критическое значение t

Матрица

1	0,192887044	0,684312193	0,459375343	-0,096493672	0,60781959
0,192887044	1	-0,08889644	-0,126901146	-0,140814452	0,19169346
0,684312193	-0,08889644	1	0,581473072	-0,40014633	0,24632132
0,459375343	-0,126901146	0,581473072	1	-0,528748472	-0,0553575
-0,096493672	-0,140814452	-0,40014633	-0,528748472	1	-0,31466597
0,607819591	0,191693465	0,246321319	-0,055357495	-0,314665968	1

0,00015	н
0,31805	н1
0,99976	Множественный коэффициент корреляции
0,99947	Скорректированный коэффициент корреляции
4211,25923	Статистику Фишера F
6,25606	Критическая статистика Фишера F

Вывод: множественный коэффициент корреляции значим

Рисунок 2.1 – Решение задачи 5.1

Далее произведём однофакторный непараметрический анализ (рисуноки 2.2-2.4).

n	20
p	0,4

Выборка					Ранжированная выборка				
8	8	7	5	9	4	7	7	8	8
5	10	7	1	12	5	10	7	1	12
6	9	9	10	11	6	9	9	10	11
4	7	7	8	8	7	10	11	12	10
9	5	9	13	7	7	6	11	7	6
9	8	7	6	7	8	8	7	5	9
9	12	8	8	5	9	5	9	13	7
7	10	11	12	10	9	8	7	6	7
10	10	8	10	7	9	12	8	8	5
7	6	11	7	6	10	10	8	10	7

1-2	1-3	1-4	1-5	2-3	2-4	2-5	3-4	3-5	4-5
9	9	16	16	0	1	1	1	1	0
25	4	16	49	9	81	4	36	25	121
9	9	16	25	0	1	4	1	4	1
9	16	25	9	1	4	0	1	1	4
1	16	0	1	25	1	0	16	25	1
0	1	9	1	1	9	1	4	4	16
16	0	16	4	16	64	4	16	4	36
1	4	9	4	1	4	1	1	0	1
9	1	1	16	16	16	49	0	9	9
0	4	0	9	4	0	9	4	1	9

79	64	108	134	73	181	73	80	74	198	Величина d
0,521212	0,612121	0,345455	0,187879	0,557576	-0,09697	0,557576	0,515152	0,551515	-0,2	Корреляция Спирмана
1,7274	2,189453	1,041194	0,541036	1,899787	0,27557	1,899787	1,7	1,870038	0,577350269	t-Статистика
									2,306004135	Критическая статистика

Рисунок 2.2 – Решение задачи 5.2

1-2		1-3		1-4		1-5		2-3		2-4	
4	7	4	7	4	8	4	8	5	9	5	13
5	10	5	7	5	1	5	12	6	11	6	7
6	9	6	9	6	10	6	11	7	7	7	8
7	10	7	11	7	12	7	10	8	7	8	5
7	6	7	11	7	7	7	6	8	7	8	6
8	8	8	7	8	5	8	9	9	9	9	10
9	5	9	9	9	13	9	7	10	7	10	1
9	8	9	7	9	6	9	7	10	11	10	12
9	12	9	8	9	8	9	5	10	8	10	10
10	10	10	8	10	10	10	7	12	8	12	8
Q	P	Q	P	Q	P	Q	P	Q	P	Q	P
2	7	0	6	4	4	5	4	6	2	9	0
5	1	0	6	0	8	8	0	7	0	3	5
4	3	4	2	4	2	7	0	0	4	3	3
4	1	5	0	5	1	6	0	0	4	1	5
1	4	5	0	2	3	1	4	0	4	1	4
1	2	0	3	0	4	4	0	3	1	2	1
0	3	3	0	3	0	1	0	0	3	0	3
0	2	0	2	0	2	1	0	2	0	2	0
1	0	0	0	0	1	0	1	0	0	1	0
0	0	0	0	0	0	0	0	0	0	0	0
18	23	17	19	18	25	33	9	18	18	22	21
S=	5	S=	2	S=	7	S=	-24	S=	0	S=	-1
t=	0,1111	t=	0,0444	t=	0,1556	t=	-0,5333	t=	0,0000	t=	-0,0222
ta=	0,486	ta=	0,486	ta=	0,486	ta=	0,486	ta=	0,486	ta=	0,486
Не значим		Не значим		Не значим		Значим		Не значим		Не значим	

Рисунок 2.3 – Решение задачи 5.2

	Ранги					Сумма рангов	Квадрат суммы рангов
	6	4,5	2,5	2	7	22	484
	2	8	2,5	1	10	23,5	552,25
	3	6	7,5	7,5	9	33	1089
	1	3	2,5	5,5	6	18	324
	8	1	7,5	10	4	30,5	930,25
	8	4,5	2,5	3	4	22	484
	8	10	5,5	5,5	1	30	900
	4,5	8	9,5	9	8	39	1521
	10	8	5,5	7,5	4	35	1225
	4,5	2	9,5	4	2	22	484
t	2	2	10	4	0	275	7993,5
T	6	6	990	60	0	1062	

W	0,2090
скор. W	0,2630
Wa	0,375977

Вывод: связь между признаками не значима

Рисунок 2.4 – Решение задачи 5.2

Вывод

В ходе выполнения работы были вычислены параметрические коэффициенты корреляции и непараметрические коэффициенты корреляции. Были использованы критерий Спирмена, коэффициент ранговой корреляции Кендалла, и коэффициент конкордации. Отсутствие значимых парных корреляций и слабая согласованность множества признаков позволяют сделать вывод о практической независимости исследуемых выборок. Работа демонстрирует применение методов непараметрической статистики для анализа взаимосвязей между переменными, что особенно ценно при работе с данными, не удовлетворяющими требованиям нормальности распределения.