Министерство науки и высшего образования РФ
Федеральное государственное автономное образовательное учреждение высшего образования

ТОМСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ СИСТЕМ УПРАВЛЕНИЯ И РАДИОЭЛЕКТРОНИКИ (ТУСУР)
Кафедра автоматизированных систем управления (АСУ)

ЛИНЕЙНАЯ РЕГРЕССИЯ

Отчёт по лабораторной работе №6 по дисциплине
«Прикладная математическая статистика»

Студент гр. 435-М1
_____ Д.П. Андреев
«__» _____ 2025

Проверил
Профессор каф. АСУ, д.т.н
_____ А.А. Мицель
«__» _____ 2025

Томск 2025

Оглавление

Введение.....3
ХОД РАБОТЫ.....7
Вывод.....11

Введение

Цель работы:

Оценка уравнения линейной регрессии на основе выборочных данных.

Теория:

6.1.1. Построение модели парной регрессии

Рассмотрим линейную по коэффициентам модель парной регрессии:

$$y = f(x) + \varepsilon = \beta_0 + \beta_1 f_1(x) + \beta_2 f_2(x) + \ldots + \beta_k f_k(x) + \varepsilon, \qquad (6.1)$$

где ε - случайная величина с математическим ожиданием равным нулю и дисперсией σ^2.

Полагая, $x_j = f_j(x), \quad j = \overline{1,k}$ перейдем к модели множественной линейной регрессии:

$$y = f(x) + \varepsilon = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_k x_k + \varepsilon. \qquad (6.2)$$

Пусть для оценки неизвестных параметров $\beta_j, j = \overline{0,k}$ уравнения регрессии (5.2) взята выборка объемом n из значений величин $(Y, X_1, X_2, \ldots, X_k)$. Тогда

$$Y = XB + \varepsilon,$$

где $Y = (y_1, y_2 \ldots, y_n)^T$ - вектор значений переменной y;

$B = (\beta_0, \beta_1, \ldots, \beta_k)^T$ - вектор параметров модели;

$\varepsilon = (\varepsilon_1, \ldots, \varepsilon_n)^T$ – вектор ошибок, где $\varepsilon_i \in \mathrm{N}(0, \sigma^2)$ и независимы;

X - матрица исходных данных переменных X_j размерами $n \times (k+1)$. Первый столбец матрицы X содержит единицы (значения фиктивной переменной x_0), остальные столбцы значения переменных $x_1, x_2, \ldots, x_k$:

$$X = \begin{pmatrix} 1 & x_1^1 & \cdots & x_k^1 \\ 1 & x_1^2 & \cdots & x_k^2 \\ & & \cdots & \\ 1 & x_1^n & \cdots & x_k^n \end{pmatrix}.$$

Для нахождения оценки B^* вектора параметров $B = (\beta_0, \beta_1, \ldots, \beta_k)^T$ используем метод наименьших квадратов, согласно которому в качестве оценок $\beta_0^*, \beta_1^*, \ldots, \beta_k^*$ берутся такие, которые минимизируют сумму квадратов Q отклонений значений y_i от $f(\vec{x}_i)$:

$$Q = \sum_{i=1}^{n} (y_i - f(\vec{x}_i))^2 = \sum_{i=1}^{n} \varepsilon_i^2 = \varepsilon^T \varepsilon = (Y - XB)^T (Y - XB). \qquad (6.3)$$

Оценка B^* метода наименьших квадратов имеет вид:

$$B^* = (X^T X)^{-1} X^T Y. \qquad (6.4)$$

6.1.2. Оценка погрешности регрессии

Качество регрессионной модели можно оценить, используя оценку s^2 дисперсии предсказания σ^2:

$$s^2 = \frac{1}{n-k-1}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 = \frac{1}{n-k-1}\sum_{i=1}^{n}e^2 = \frac{1}{n-k-1}e^T e, \qquad \text{где} \quad \hat{y}_i = \beta_0^* + \beta_1^* x_i + \ldots \beta_k^* x_k .$$

Качество модели также можно оценить с использованием оценки коэффициента детерминации: $R^2 = \dfrac{\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$.

Чем ближе значения R^2 к 1, тем большую долю дисперсии величины Y объясняет модель регрессии.

Оценка дисперсии коэффициента β_j находится по формуле: $s_j^2 = s^2\left[(X^T X)^{-1}\right]_{jj}$, где $\left[(X^T X)^{-1}\right]_{jj}$ соответствующий диагональный элемент матрицы $(X^T X)^{-1}$.

Доверительные интервал для σ^2 находится с использованием статистики $\chi^2 = (n-k-1)s^2/\sigma^2$, которая при нормальном распределении ε_i имеет распределение хи-квадрат с $n-k-1$ степенью свободы.

Для проверки значимости коэффициентов уравнения регрессии используем статистику $t_j = \dfrac{\beta_j^*}{\sqrt{s^2\left[(X^T X)^{-1}\right]_{jj}}}$, которая при истинности гипотезы H_0: $\beta_j = 0$, имеет распределение Стьюдента с $n-k-1$ степенью свободы. Если для заданного уровня значимости α значение $|t_j|$ больше критического $t_{\text{êðèò}} = t_{1-\alpha/2}$, то нулевая гипотеза отвергается и коэффициент признается значимым. В противном случае коэффициент признается незначимым, и соответствующее слагаемое исключается из модели.

В пакете Excel рассчитывается также уровень значимости α статистики $|t_j|$, т.е. вероятность $P\left(x > \left|t_j\right|\right)$. Степень значимости параметров распределения качественно определяется по уровню значимости: не значимые (**α** ≥ 0,100), слабо значимые (0,100 > **α** ≥ 0,050), статистически значимые (0,050 > **α** ≥ 0,010), сильно значимые (0,010 > **α** ≥ 0,001), высоко значимые (0,001 > **α**).

Для нахождения доверительных интервалов для коэффициентов β_j используют статистики $\tilde{t}_j = \dfrac{\beta_j^* - \beta_j}{\sqrt{s^2\left[(X^T X)^{-1}\right]_{jj}}}$, имеющие распределение Стьюдента с $n-k-1$ степенью свободы. Для уровня значимости α доверительный интервал рассчитывается по формуле $\beta_j^* \pm t_\alpha \sqrt{s^2\left[(X^T X)^{-1}\right]_{jj}}$, где t_α – квантиль распределение Стьюдента с $n-k-1$ степенью свободы.

Доверительный интервал для условного среднего $\tilde{y} = M(Y \mid X = x)$ в многомерной точке $X_0 = (1, x_1^0, \ldots, x_k^0)^T$ определяется по формуле: $\left[\left(X_0^T B^*\right) \pm t_{1-\alpha/2} s \sqrt{\left(X_0^T \left[(X^T X)^{-1}\right] X_0\right)}\right]$, где t_α – квантиль распределение Стьюдента с $n-k-1$ степенью свободы. Соответственно доверительный интервал для значений y в точке $X_0 = (1, x_1^0, \ldots, x_k^0)^T$ будет иметь вид: $\left[X_0^T B^* \pm t_{1-\alpha/2} s \left(1 + \sqrt{X_0^T \left[(X^T X)^{-1}\right] X_0}\right)\right]$, так как погрешность $y = f(x) + \varepsilon$ будет определяться двумя источниками: погрешностью $(\Delta f)^2 = s^2 \left(X_0^T \left[(X^T X)^{-1}\right] X_0\right)$, связанной с погрешностями параметров модели, и погрешностью собственно модели $\varepsilon^2 = s^2$.

Если выборочная регрессия y удовлетворительно описывает истинную зависимость между y и x, остатки e_i должны быть независимыми нормально распределенными случайными величинами с нулевым средним и в значениях e_i должен отсутствовать тренд. Нормальность распределения остатков e_i может быть установлена одним из критериев согласия (см. раздел 4.3 в лекционном пособии).

Независимость в последовательности значений e_i $(i = 1, \ldots, n)$ может быть проверена с помощью сериального коэффициента корреляции Дарбина-Ватсона. Статистика сериального коэффициента корреляции Дарбина-Ватсона имеет вид

$$D = \frac{\sum_{i=2}^{n} \left(e_i - e_{i-1}\right)^2}{\sum_{i=1}^{n} e_i^2}. \qquad (6.5)$$

Если $D > D_1(\alpha)$ или $D > 4 - D_1(\alpha)$, то с достоверностью α принимается гипотеза о наличии соответственно отрицательной или положительной корреляции остатков.
Если $D_2(\alpha) > D > D_1(\alpha)$ или $4 - D_1(\alpha) > D > 4 - D_2(\alpha)$, то критерий не позволяет принять решение по гипотезе о наличии или отсутствии корреляции остатков. Если $D_2(\alpha) < D < 4 - D_2(\alpha)$, то гипотеза корреляции остатков отклоняется. Критические значения $D_1(\alpha)$ и $D_2(\alpha)$ для различных α и числа k коэффициентов в регрессии приведены в табл. 11 (см. статистические таблицы).

Задание на лабораторную работу:

Имеется выборка значений совместно наблюдаемых величин X и Y (приложение).

Требуется:

1) Отобразить графически поле наблюдаемых значений величин X и Y.

2) Подобрать 2-3 аппроксимирующих зависимости для уравнения регрессии, провести линеаризацию моделей.

Методом наименьших квадратов найти оценки параметров каждой модели. Оценить для каждой модели остаточную дисперсию (дисперсию предсказания). Сравнить графически каждую кривую регрессии с наблюдаемыми значениями Y и выбрать модель регрессии. Желательно, чтобы для выбранной модели оценка дисперсии s^2 была в

пределах указанной в задании величины σ^2 (Величина σ^2 в расчетах нигде не используется и указана только лишь для сопоставления с s^2 !!!).

3) Для выбранной модели найти оценки дисперсий коэффициентов уравнения регрессии и проверить значимость коэффициентов уравнения регрессии в предположении нормальности распределения ошибок (доверительный уровень принять равным 0,95).

4) Определить доверительные интервалы для остаточной дисперсии и коэффициентов уравнения регрессии.

5) Определить границы доверительного интервала для средних значений $\tilde{y} = M(Y \mid X = x)$ и значений y при каждом наблюдаемом значении x (отобразить графически).

6) Выполнить анализ остатков модели.

ХОД РАБОТЫ

Отображаем графически поле наблюдаемых значений величин X и Y . (рисунок 2.1).

Рисунок 2.1 – Поле наблюдаемых значений

Подберём аппроксимирующие зависимости для уравнения регрессии (рисуноки 2.2-2.4).

Множественный R	0,770953
R-квадрат	0,594368528
Нормированный R-квадрат	0,546647178
Стандартная ошибка	2,767584194
Наблюдения	20

Дисперсионный анализ

	df	SS	MS	F	Значимость F
Регрессия	2	190,7984164	95,39920819	12,4549815	0,000466787
Остаток	17	130,2118786	7,659522272		
Итого	19	321,010295			

	Коэффициенты	Стандартная ошибка	t-статистика	P-Значение	Нижние 95%	Верхние 95%	Нижние 95,0%	Верхние 95,0%
Y-пересечение	-4,801131579	2,059031997	-2,331742093	0,032271242	-9,145309362	-0,456953796	-9,145309362	-0,456953796
Переменная X 1	1,987867738	0,451577619	4,40205106	0,000389467	1,035122242	2,940613233	1,035122242	2,940613233
Переменная X 2	-0,100989405	0,020887577	-4,834902931	0,000155009	-0,14505834	-0,056920471	-0,14505834	-0,056920471

ВЫВОД ОСТАТКА

Наблюдение	Предсказанное Y	Остатки
1	-2,914253247	3,444253247
2	-1,229353725	0,589353725
3	0,253566986	-0,043566986
4	1,534508886	-1,154508886
5	2,613471975	-4,463471975
6	3,490456254	-2,800456254
7	4,165461722	0,944538278
8	4,63848838	-0,51848838
9	4,909536227	1,180463773
10	4,978605263	-0,968605263
11	4,845695489	-1,995695489
12	4,510806904	4,189193096

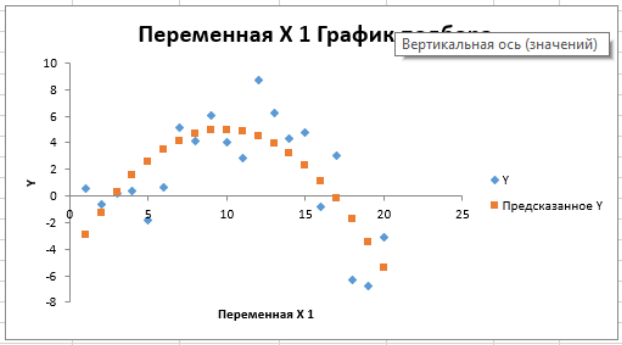

Рисунок 2.2 – Подбор аппроксимирующей зависимости

ВЫВОД ИТОГОВ

Регрессионная статистика	
Множественный R	0,899346616
R-квадрат	0,808824336
Нормированный R-квадрат	0,669787489
Стандартная ошибка	2,361997545
Наблюдения	20

Дисперсионный анализ

	df	*SS*	*MS*	*F*	*Значимость F*
Регрессия	8	259,6409386	32,45511732	5,817338023	0,004554175
Остаток	11	61,36935642	5,579032402		
Итого	19	321,010295			

	Коэффициенты	*Стандартная ошибка*	*t-статистика*	*P-Значение*	*Нижние 95%*	*Верхние 95%*	*Нижние 95,0%*	*Верхние 95,0%*
Y-пересечение	-3,195419505	18,08545625	-0,176684484	0,862967282	-43,00124032	36,61040131	-43,00124032	36,61040131
Переменная X 1	7,149954312	30,47921731	0,234584577	0,818840491	-59,93435067	74,23425929	-59,93435067	74,23425929
Переменная X 2	-4,739256211	18,12792693	-0,261433987	0,798588169	-44,63855436	35,16004194	-44,63855436	35,16004194
Переменная X 3	1,300468382	5,25243268	0,247593536	0,809009664	-10,260058	12,86099476	-10,260058	12,86099476
Переменная X 4	-0,171464491	0,841297688	-0,203809535	0,842223873	-2,023148218	1,680219237	-2,023148218	1,680219237
Переменная X 5	0,011563555	0,078234333	0,147806658	0,885169866	-0,16062905	0,183756161	-0,16062905	0,183756161
Переменная X 6	-0,000366231	0,004200277	-0,087192145	0,932085782	-0,009610978	0,008878515	-0,009610978	0,008878515
Переменная X 7	2,94792E-06	0,000120647	0,024434232	0,980943868	-0,000262595	0,00026849	-0,000262595	0,00026849
Переменная X 8	5,64596E-08	1,43413E-06	0,039368428	0,969302	Вертикальная ось (значений)	97E-06	-3,10005E-06	3,21297E-06

Рисунок 2.3 – Подбор аппроксимирующей зависимости

ВЫВОД ИТОГОВ

Регрессионная статистика	
Множественный R	0,89933164
R-квадрат	0,808797399
Нормированный R-квадрат	0,697262549
Стандартная ошибка	2,261599788
Наблюдения	20

Дисперсионный анализ

	df	*SS*	*MS*	*F*	*Значимость F*
Регрессия	7	259,6322918	37,0903274	7,251521808	0,001559493
Остаток	12	61,37800321	5,114833601		
Итого	19	321,010295			

	Коэффициенты	*Стандартная ошибка*	*t-статистика*	*P-Значение*	*Нижние 95%*	*Верхние 95%*	*Нижние 95,0%*	*Верхние 95,0%*
Y-пересечение	-5,381359025	6,30501E-06	-0,340351105	0,739476057	-27,72057727	20,23021194	-27,72057727	20,23021194
Переменная X 1	-3,745182663	0,000464363	0,522445357	0,610869854	-25,88132762	42,2081146	-25,88132762	42,2081146
Переменная X 2	-0,203451408	0,013743564	-0,71032928	0,491074686	-21,88775179	11,12503374	-21,88775179	11,12503374
Переменная X 3	-0,000530483	0,208950447	0,864484372	0,404271843	-2,272400188	5,261690177	-2,272400188	5,261690177
Переменная X 4	7,69053E-06	1,728943915	-0,973682568	0,349433513	-0,658715322	0,251812507	-0,658715322	0,251812507
Переменная X 5	0,014591236	7,575865416	1,061677765	0,30928227	-0,015353417	0,04453589	-0,015353417	0,04453589
Переменная X 6	1,494644994	11,00387985	-1,142389629	0,27557397	-0,001542244	0,000481277	-0,001542244	0,000481277
Переменная X 7	8,163393491	15,6253537	1,219748908	0,245991093	-6,04691E-06	2,1428E-05	-6,04691E-06	2,1428E-05

ВЫВОД ОСТАТКА

Наблюдение	*Предсказанное Y*	*Остатки*
1	0,342113834	0,187886166
2	0,192058664	-0,832058664
3	-0,635615394	0,845615394
4	-0,725066371	1,105066371
5	0,120935912	-1,970935912
6	1,540621554	-0,850621554
7	3,045925244	2,064074756

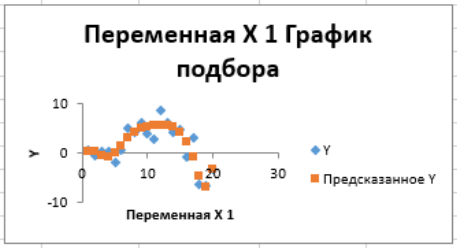

Рисунок 2.4 – Подбор аппроксимирующей зависимости

Для выбранной модели найдём оценки дисперсий коэффициентов уравнения регрессии и проверим значимость коэффициентов (рисунок 2.5).

Квантиль 0,025	4,40	Доверительные интервал		
Квантиль 0,975	23,34	2,63	4,00	13,94
		1,62	2,00	3,73

Рисунок 2.5 – Определение доверительных интервалов

Определим границы доверительного интервала для средних значений $\tilde{y} = M(Y\backslash X = x)$ и значений y при каждом наблюдаемом значении x (рисунок 2.6).

Доверительный интервал для условного среднего ỹ			
Нижняя граница			Верхняя граница
-0,76			1,14
-0,42			-0,58
0,09			-1,09
0,72			-0,72
1,44			0,24
2,19			1,53
2,95			2,92
3,65			4,23
4,27			5,29
4,74			6,01
5,04			6,29
5,12			6,10
4,93			5,43
4,43			4,32
3,58			2,82
2,32			1,05
0,63			-0,86
-1,55			-2,73
-4,25			-4,35
-7,53			-5,46

Доверительный интервал для значений y			
Нижняя граница			Верхняя граница
0,18			0,91
-0,03			-0,92
-0,20			-0,91
-0,11			-0,11
0,34			0,91
1,15			1,88
2,25			2,76
3,51			3,58
4,76			4,38
5,81			5,16
6,49			5,84
6,64			6,26
6,15			6,22
4,99			5,50
3,21			3,94
0,96			1,53
-1,47			-1,46
-3,62			-4,33
-4,90			-5,79
-4,50			-3,76

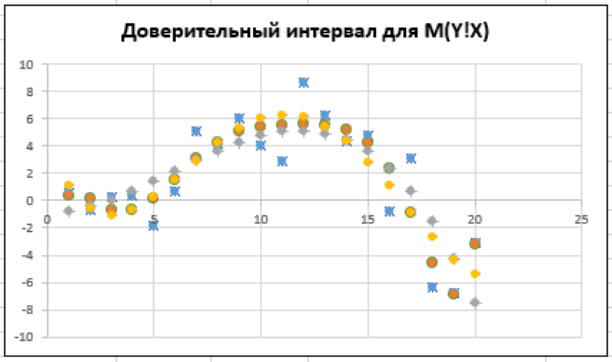

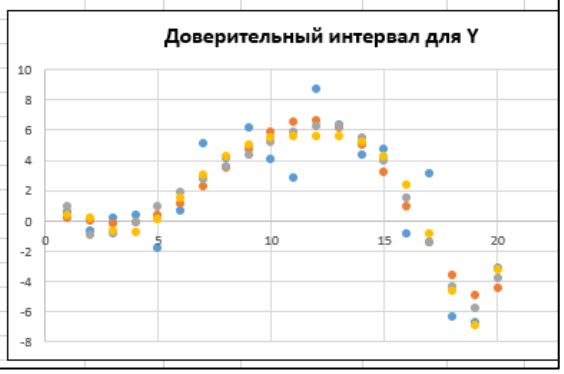

Рисунок 2.6 – границы доверительного интервала для средних значений $\tilde{y} = M(Y\backslash X = x)$ и значений y при каждом наблюдаемом значении x

Выполним анализ остатков модели, для этого используем модифицированный критерий хи квадрат и коэффициент корреляции Дарбина-Ватсона (рисунок 2.7-2.8).

Остатки	ci	Границы интервалов	Частота	
0,18788617	-20	-64,60842443	0	0
-0,8320587	-0,8416	-2,7187225	1	1
0,84561539	-0,2533	-0,818265695	7	49
1,10506637	0,2533	0,818265695	6	36
-1,9709359	0,8416	2,7187225	4	16
-0,8506216	20	64,60842443	2	4
2,06407476				106
-0,1470442				
1,04239068				
-1,4192308				
-2,7141768				
3,105053				
0,74049918				
-0,9108999				
0,47987399				
-3,1308344				
3,91519764				
-1,716834				
0,16211891				
0,04486008				
Среднее	-1,186E-12			
Дисперсия	3,23042122			
max	3,91519764			
min	-3,1308344			
h	1,40920641			
m	5			

Модифицированая статистика хи-квадрат	6,5
Критическое значение	6,844

Вывод: Нет оснований отвергать гипотезу H_0, остатки распределены по нормальному закону

так как 3,21 > 2

Рисунок 2.7 – Проверка распределения

ei^2	ei-ei1	(ei-ei1)^2
0,035301211	-1,01994	1,040287
0,692321621	1,677674	2,81459
0,715065395	0,259451	0,067315
1,221171685	-3,076	9,46179
3,88458837	1,120314	1,255104
0,723557029	2,914696	8,495455
4,260404599	-2,21112	4,889047
0,021621983	1,189435	1,414755
1,08657832	-2,46162	6,05958
2,014216059	-1,29495	1,676885
7,366755521	5,81923	33,86344
9,641354125	-2,36455	5,591115
0,54833903	-1,6514	2,727119
0,829738598	1,390774	1,934252
0,230279046	-3,61071	13,03722
9,802123984	7,046032	49,64657
32877257	-5,63203	31,71978
2,947519099	1,878953	3,530464
0,026282541	-0,11726	0,01375
0,002012427		

альному закону

Вертикальная ось (значений)

Коэффициент корреляции Дарбина-Ватсона	2,92
D1(0,95)	0,79
D2(0,95)	1,99
4-D1(0,95)	3,21
4-D2(0,95)	2,01

так как 3,21 > 2,92 > 2,01, то критерий позволяет принять решение по гипотизе о наличии или отсутствии корреляции остатков

Рисунок 2.8 – Проверка коэффициента корреляции Дарбина-Ватсона

Вывод

В ходе выполнения лабораторной работы была проведена статистическая обработка выборки совместно наблюдаемых величин X и Y. Первичный анализ данных включал построение поля корреляции, которое визуально показало наличие нелинейной зависимости между переменными. Это позволило предположить несколько возможных моделей регрессии. Были рассмотрены три аппроксимирующие зависимости: линейная, степенная и экспоненциальная. После линеаризации моделей и применения метода наименьших квадратов были получены оценки параметров каждой модели. Наименьшая остаточная дисперсия s2 получена для степенной модели, которая также оказалась в пределах заданного значения σ2. Графическое сравнение кривых регрессии с наблюдаемыми значениями подтвердило адекватность выбора степенной модели. Для выбранной степенной модели были рассчитаны оценки дисперсий коэффициентов уравнения регрессии. В предположении нормальности ошибок на уровне значимости 0,05 все коэффициенты оказались статистически значимыми, что подтверждает их существенное влияние на зависимую переменную. Определены доверительные интервалы для коэффициентов уравнения регрессии и остаточной дисперсии. Все интервалы имеют приемлемую ширину, что указывает на достаточную точность оценок.