Министерство науки и высшего образования РФ
Федеральное государственное автономное образовательное учреждение высшего образования

ТОМСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ СИСТЕМ УПРАВЛЕНИЯ И РАДИОЭЛЕКТРОНИКИ (ТУСУР)
Кафедра автоматизированных систем управления (АСУ)

ОЦЕНКА ЗАКОНА РАСПРЕДЕЛЕНИЯ НА ОСНОВЕ ВЫБОРОЧНЫХ ДАННЫХ

Отчёт по лабораторной работе №3 по дисциплине
«Прикладная математическая статистика»

Студент гр. 435-М1
_____ Д.П. Андреев
«__» _____ 2025

Проверил
Профессор каф. АСУ, д.т.н
_____ А.А. Мицель
«__» _____ 2025

Томск 2025

Оглавление

Введение.....3
1 КРАТКАЯ ТЕОРИЯ.....5
2 ХОД РАБОТЫ.....10
Вывод.....13

Введение

Цель работы:

Оценка закона распределения генеральной совокупности на основе выборочных данных.

Задание на лабораторную работу:

Имеется выборка объемом $n = 100$ из известного распределения F (см. приложение 3.1). Предполагается, что F может быть одним из следующих распределений:

1) F - нормальное распределение с плотностью $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-a)^2}{2\sigma^2}}$, $x \in R$, где a и $\sigma > 0$ – параметры;

2) F - показательное распределение с плотностью $f(x) = \lambda e^{-\lambda x}$, $x > 0$, где $\lambda > 0$ – параметр;

3) F - равномерное распределение на отрезке $[a, b]$, где a и b – параметры.

Требуется:

1) Представить выборку в виде группированного статистического ряда. Количество интервалов равно $m = 1 + 3{,}322 \cdot \lg(n) = 7$. При разбивке на интервалы следует следить за тем, чтобы частоты n_i для всех интервалов были одного порядка, причем количество выборочных значений n_i попавших в каждый интервал должно быть не меньше 5 ($n_i \geq 5 \quad \forall i = \overline{1,m}$). Допускается $1 < n_i < 5 \quad \forall i = \overline{1,m}$ не более, чем в 2-х интервалах. В противном случае следует объединять соседние интервалы, добиваясь относительно равномерного распределения частот по интервалам.

2) Найти числовые характеристики выборки: выборочное среднее $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$, выборочную дисперсию $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$, выборочный коэффициент асимметрии $\bar{A} = \frac{1}{n \cdot s^3}\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^3$ и выборочный коэффициент эксцесса

$$\bar{E} = \frac{1}{n \cdot s^4} \sum_{i=1}^{n} \left(x_i - \bar{x} \right)^4 - 3 .$$

3) Построить гистограмму и сравнить ее с гистограммой плотности теоретического распределения. При построении кривых плотностей параметры теоретических распределений заменить оценками, найденными по методу максимального правдоподобия или по методу моментов.

4) Выдвинуть гипотезу H_0 о виде закона распределения (на основе сравнения гистограммы с графиком плотности теоретического распределения).

5) Используя критерий Пирсона для сложной гипотезы, проверить гипотезу H_0 для уровня значимости $\alpha = 0,05$.

6) Проверить гипотезу H_0 на основе критериев сравнения интегральных функций распределения вероятностей. При этом теоретические распределения рассчитываются с использованием точных значений параметров.

7) Проверить гипотезу H_0 на основе специальных критериев сравнения функций распределения вероятностей. При этом теоретические распределения рассчитываются с использованием выборочных значений параметров.

8) Сделать выводы

1 КРАТКАЯ ТЕОРИЯ

3.1.1 Критерии, основанные на сравнении теоретической плотности распределения и эмпирической гистограммы

Критерий χ^2 (Пирсона) для простой гипотезы

Пусть $\{x_1, x_2, \ldots, x_n\}$ выборка из генеральной совокупности F. Проверяется гипотеза $H_0 : F = F_1$ против альтернативы $H_1 : F \neq F_1$.

Представим выборку в виде группированного ряда, разбив предполагаемую область значений случайной величины на $m = 1 + 3{,}322 \cdot \lg n$ интервалов. Пусть n_i - число элементов выборки попавших в i-ый интервал, а p_i - теоретическая вероятность попадания в этот интервал при условии истинности H_0. Составим статистику $\rho(x) = \sum_{i=1}^{m} \frac{(n_i - np_i)^2}{np_i}$, которая характеризует сумму квадратов отклонения наблюдаемых значений n_i от ожидаемых np_i по всем интервалам группирования.

Теорема Пирсона. Если H_0 верна, то при фиксированном m и $n \to \infty$

$$\rho(x) = \sum_{i=1}^{m} \frac{(n_i - np_i)^2}{np_i} \Rightarrow \chi^2(m-1).$$

Таким образом, статистику $\rho(x)$ можно использовать в качестве статистики критерия согласия для проверки гипотезы о виде закона распределения, который будет иметь вид:

$$F_n(x) = \begin{cases} H_0, & \rho(x) < \chi^2_{1-\alpha}(m-1) \\ H_1, & \rho(x) \geq \chi^2_{1-\alpha}(m-1) \end{cases}, \quad \rho(x) = \sum_{i=1}^{m} \frac{(n_i - np_i)^2}{np_i},$$

где $\chi^2_{1-\alpha}(m-1)$-квантиль распределения $\chi^2(m-1)$ с $(m-1)$ степенями свободы.

Данный критерий называется критерием χ^2 или критерием согласия Пирсона.

Замечание. Критерий не состоятелен для альтернатив, для которых $\tilde{p}_i = p_i$ для всех $i \in \{1, 2, \ldots, m\}$. Поэтому, следует стремиться к как можно большему числу интервалов группирования. Однако, с другой стороны, сходимость к χ^2 величины $\frac{(n_i - np_i)^2}{np_i}$ обеспечивается ЦПТ, то есть ожидаемое значение np_i для каждой ячейки не должно быть слишком мало. Поэтому обычно число интервалов выбирают таким образом, чтобы $np_i \geq 5$.

Критерий χ^2 (Пирсона) для сложной гипотезы

Пусть $\{x_1, x_2, \ldots, x_n\}$ выборка из генеральной совокупности F. Проверяется сложная гипотеза $H_0 : F = F_\theta$, где θ - неизвестный параметр распределения F (или вектор параметров), против альтернативы $H_1 : F \neq F_\theta$.

Пусть выборка по прежнему представлена в виде группированного ряда и n_i - число элементов выборки попавших в i-ый интервал, $i \in \{1,2,\ldots,m\}$. Статистику (2.1) мы не можем в этом случае использовать для построения критерия Пирсона, так как не можем вычислить теоретические значения вероятностей p_i, которые зависят от неизвестного параметра θ. Пусть θ^* - оценка параметра θ, а $p_i^*(\theta^*)$ - соответствующие ей оценки вероятностей p_i. Составим статистику $\rho(x) = \sum_{i=1}^{m} \frac{\left(n_i - np_i^*\right)^2}{np_i^*}$.

Теорема Пирсона. Если H_0 верна, и l - число компонент вектора θ (число неизвестных параметров распределения), то при фиксированном m и $n \to \infty$

$$\rho(x) = \sum_{i=1}^{m} \frac{\left(n_i - np_i^*\right)^2}{np_i^*} \Rightarrow \chi^2_{m-l-1}.$$

Таким образом, критерий Пирсона для параметрической гипотезы будет иметь вид:

$$F_n(x) = \begin{cases} H_0, & \rho(x) < \chi^2_{1-\alpha}(m-l-1) \\ H_1, & \rho(x) \geq \chi^2_{1-\alpha}(m-l-1) \end{cases},$$

где $\chi^2_{1-\alpha}(m-l-1)$ - квантиль распределения $\chi^2(m-l-1)$ с $(m-l-1)$ степенями свободы.

3.1.2 Критерии, основанные на сравнении теоретической и эмпирической функций распределения вероятностей

Пусть $F_n(x)$ – эмпирическая функция распределения случайной величины x, представленной выборкой $x_1 \leq x_2 \leq \ldots \leq x_n$:

$$F_n(x) = \begin{cases} 0, \ x < x_1; \\ \dfrac{i}{n}, \ x_i \leq x \leq x_{i+1}, \ 1 \leq i \leq n-1; \\ 1, \ x \geq x_n. \end{cases}$$

Для проверки нулевой гипотезы $H_0 : F_n(x) = F(x)$, где $F(x)$ – полностью определенная (с точностью до параметров) теоретическая функция распределения, рассматривается расстояние между эмпирической и теоретической функциями распределения

Критерий Колмогорова-Смирнова

Для практического применения используются формулы

$$D_n^+ = \max_{1 \le i \le n}\left(\frac{i}{n} - F(x_i)\right);\ D_n^- = \max_{1 \le i \le n}\left(F(x_i) - \frac{i-1}{n}\right);\ D_n = \max\left(D_n^+, D_n^-\right).$$

Здесь $F(x_i)$ – теоретическая функция распределения.

Критические значения статистики Колмогорова-Смирнова для уровня значимости $0{,}01 \le \alpha \le 0{,}2$ вычисляются по формуле

$$D_n(\alpha) = \left(\frac{-\ln(\alpha/2)}{2n}\right)^{1/2} - \frac{1}{6n}.$$

Критерий Колмогорова

Статистика Колмогорова вычисляется по формуле

$$D_n = \max\left|F_n(x) - F(x)\right|.$$

Критическое значение $D_n(\alpha)$ для статистики $D_n\sqrt{n}$ приведены в таблице 3.1

Таблица 3.1

α	0.1	0.05	0.02	0.01	0.001
$D_n(\alpha)$	1.224	1.358	1.52	1.627	1.95

Критерий Смирнова-Крамера-фон Мизеса

Статистика критерия имеет вид

$$w^2 = \frac{1}{12n} + \sum_{i=1}^{n}\left\{F(x_i) - \frac{2i-1}{2n}\right\}^2,$$

где $F(x)$ – теоретическая функция распределения.

При объеме выборки $n > 40$ можно использовать приведенные в табл. 3.2 квантили распределения w^2, которые следуют из его предельного распределения (α – уровень значимости, принятый для проверки H_0).

Таблица 3.2. Квантили распределения w^2 ([1], стр. 217)

α	0,900	0,950	0,990	0,995	0,999
$w^2(\alpha)$	0,3473	0,4614	0,7435	0,8694	1,1679

3.1.3 Специальные критерии проверки нормальности распределения

Модифицированный критерий χ^2

Статистика критерия подсчитывается по формуле

$$\chi^2 = \frac{m}{n}\sum_{i=1}^{m} n_i^2 - n,$$

где n – объем выборки; n_i – количество членов выборки, попавшие в i -й интервал. Границы интервалов определяются как

$$a_i = \bar{x} + c_i s \ \ (i = 0,1,...,m).$$

Здесь $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i,\ s = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}$; $m = 1 + 3{,}322\lg n$ – количество интервалов.

Значения коэффициентов c_i для $m = 7$ приведены в табл. 3.3.

Таблица 3.3. Значения коэффициентов c_i модифицированного χ^2-критерия нормальности для $m = 7$ ([1], стр. 231)

m	c_0	c_1	c_2	c_3	c_4	c_5	c_6	c_7
7	$-\infty$	-1,0676	-0,5659	-0,1800	0,1800	0,5659	1,0676	∞

Если $\chi^2 > d_m(\alpha)$, где $d_m(\alpha)$ – критическое значение статистики критерия на уровне значимости α, то гипотеза нормальности отклоняется. Критические значения $d_m(\alpha)$ для $m = 7$ приведены в табл. 3.4

Таблица 3.4. Критические значения $d_m(\alpha)$ модифицированного χ^2 - критерия нормальности для $m = 7$ ([1], стр. 232)

m	α		
	0,10	0,05	0,01
7	8,322	10,038	13,837

Критерий типа Колмогорова – Смирнова

Модифицированная статистика для проверки нормальности распределения в ситуации, когда оба его параметра оцениваются по выборке рассчитывается по формуле

$$D_n^н = D_n\left(\sqrt{n} - 0{,}01 + \frac{0{,}85}{\sqrt{n}}\right).$$

Критические значения $D_n^н(\alpha)$ (α – уровень значимости) приведены в табл. 3.5

Таблица 3.5. Критические значения статистики Колмогорова – Смирнова, модифицированной для проверки нормальности распределения ([1], стр. 233).

α	0,15	0,10	0,05	0,03	0,01
$D_n^н(\alpha)$	0,775	0,819	0,895	0,955	1,035

Критерий Фроцини

Статистика Фроцини рассчитывается по формуле

$$B_n = \frac{1}{\sqrt{n}}\sum_{i=1}^{n}\left|F^*(z_i) - \frac{2i-1}{2n}\right|,$$

где $z_i = \frac{x_i - \bar{x}}{s}$; $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$, $s = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}$; $F^*(z) = \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{z} e^{-\frac{1}{2}t^2}\,dt$.

Критические значения статистики B_n приведены в таблице 3.6.

Таблица 3.6 Критические значения статистики Фроцини B_n для проверки нормальности распределения. Здесь α – уровень значимости ([1], стр. 235)

n	α		
	0,9	0,95	0,99
20	0,2556	0,2839	0,3363
∞	0,2560	0,2840	0,3410

2 ХОД РАБОТЫ

Представим выборку в виде группированного статистического ряда. Также найдём числовые характеристики выборки (рисунок 2.1).

μ=	2	n=	100	max=	17,58	min=	-9,79
σ=	5	h=	3,91	m=	7	ное отклонение=	4,964578443

5,905	2,089	-0,54	-1,76	-0,32	2,653	2,591	-0,77	-8,72	-6,09
2,752	8,509	3,658	3,583	-0,91	0,96	-3,7	6,593	-2,09	0,058
1,013	-9,79	0,862	1,67	4,889	1,696	6,856	-6,17	1,606	4,305
-2,78	-0,23	1,763	-6,66	-5,1	12,8	-2,02	-1,87	-5,89	4,256
5,554	-2,16	4,859	-0,39	3,725	-2,08	5,382	-0,66	5,4	5,062
0,673	-1,57	5,876	4,409	3,775	1,657	-0,52	-7,42	11,83	9,073
7,574	5,853	12,65	1,74	0,566	6,627	2,047	3,326	-6,31	1,257
4,689	-1,38	-3,85	9,836	6,439	6,108	6,025	-0,55	6,035	-3,47
2,015	-1,23	5,246	3,273	7,755	4,351	-0,19	6,378	4,582	5,176
13	-2,34	-7,11	4,14	-2,56	-1,05	17,58	3,33	2,854	0,502

Выборочное среднее	Выборочная дисперсия
1,99	24,65
Коэффициент ассиметрии	Коэффициент эксцесса
0,18	0,51

Диапазон	Частоты	Относительные частоты	Накопительные частоты	Изменённый диапазон	Изменённые частоты	Середины интервалов	Плотность частоты	Теоретическая плотность показательного распределения	Вероятность попадения в интервал pi*	Значения npi*
-9,79	1	0,01	0,01	-9,79	9	-9,79	0,00495	0,01935	0,048326	4,83
-5,88	8	0,08	0,09	-1,97	11	-1,97	0,05822	0,22762	0,156085	15,61
-1,97	11	0,11	0,2	1,94	30	1,94	0,07978	0,31195	0,281615	28,16
1,94	30	0,3	0,5	5,85	29	5,85	0,05932	0,23194	0,284137	28,41
5,85	29	0,29	0,79	9,76	15	9,76	0,02393	0,09356	0,160319	16,03
9,76	15	0,15	0,94	17,58	6	17,58	0,00062	0,00243	0,050533	5,05
13,67	5	0,05	0,99							
17,58	1	0,01	1							
	100									

Рисунок 2.1 – Решение задачи

Далее построим гистограмму и сравним ее с гистограммой плотности теоретического распределения (рисунок 2.2).

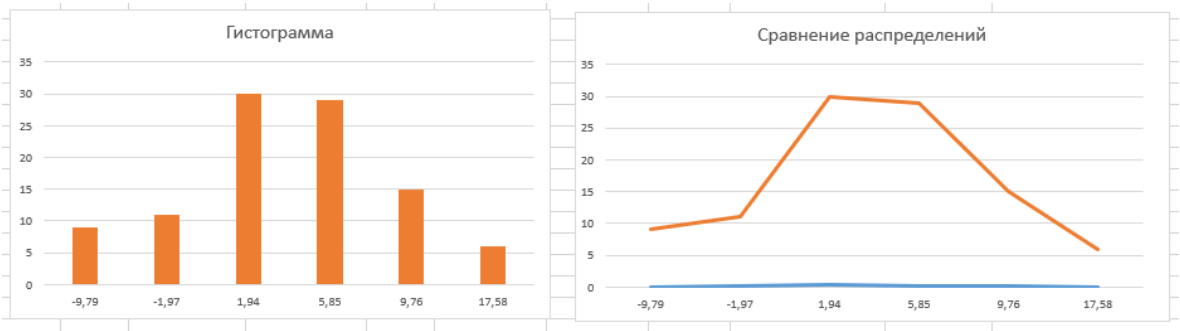

Рисунок 2.2 – Гистограммы и их сравнение

Используя критерий Пирсона для сложной гипотезы, проверить гипотезу (рисунок 2.3)

x2	
3,593750	
1,360677	
0,120024	
0,012097	
0,066417	
0,177347	
5,330312	Статистика наблюдаемая
9,487729	Статистика критическая

Вывод: Нет оснований отвергать гипотезу H_0, распределение можно считать нормальным

Рисунок 2.3 – Критерий Пирсона

Далее проверим гипотезу на основе критериев сравнения интегральных функций распределения вероятностей (рисунок 2.4-2.6).

Выборка	Сорт	+	-	D+	D-
5,905	-9,79	0,000813154	0,009186846	0,067379	0,042704472
2,752	-8,72	0,003983557	0,006016443		
1,013	-7,42	0,000217512	0,009782488		
-2,78	-7,11	0,005772507	0,004227493		
5,554	-6,66	0,008363219	0,001636781		
0,673	-6,31	0,011743613	-0,001743613		
7,574	-6,17	0,018870575	-0,008870575		
4,689	-6,09	0,027168701	-0,017168701		

Критерий Колмогорова-Смирнова:

Статистика Колмогорова-Смирнова	0,06738
Критическое значение статистики Колмогорова-Смирнова:	0,13414

Вывод: Нет оснований отвергать гипотезу H_0, распределение можно считать нормальным

Рисунок 2.4 – Критерий Колмогорова-Смирнова

Теоретическое интегральное распределение	Эмпирическое интегральное распределение	Отклонение между теоретическим и эмпирическим распределением для простой гипотезы
0,009186846	0,0001	0,009086846
0,213597716	0,0009	0,212697716
0,495212808	0,002	0,493212808
0,779350054	0,005	0,774350054
0,939668888	0,0079	0,931768888
0,999083389	0,0094	0,989683389

Статистика Колмогорова:	0,98968
Критическое значение статистики Колмогорова:	1,358

Критерий Колмогорова:

Вывод: Нет оснований отвергать гипотезу H_0, распределение можно считать нормальным

Рисунок 2.5 – Критерий Колмогорова

Критерий Смирнова-Крамера-фон Мизеса:

Статистика Смирнова-Крамера-фон Мизеса	0,130097
Критическое значение статистики Смирнова-Крамера-фон Мизеса	0,461400

w
0,000851
0,000834
0,000856
0,000834

Вывод: Нет оснований отвергать гипотезу H_0, распределение можно считать нормальным

Рисунок 2.6 – Критерий Смирнова-Крамера-фон Мизеса

Теперь проверим гипотезу на основе специальных критериев сравнения функций распределения вероятностей (рисунок 2.7-2.9).

Модифицированый критерий:

Среднее	1,99
Отклонение	4,964578443

Коэффициенты ci	Границы интервалов	Частоты	
-10	-47,65532443	0	0
-1,0676	-3,309723946	13	169
-0,5659	-0,818994941	14	196
-0,1800	1,09683588	16	256
0,1800	2,88408412	14	196
0,5659	4,799914941	14	196
1,0676	7,290643946	19	361
10	51,63624443	10	100
			1474

Модифицированая статистика хи-квадрат	3,18
Критическое значение	10,038

Вывод: Нет оснований отвергать гипотезу H_0, распределение можно считать нормальным

Рисунок 2.7 – Модифицированный критерий χ^2

Критерий типа Колмогорова – Смирнова:

Поправочный коэффициент
10,075

Статистика типа Колмогорова – Смирнова	0,67884281
Критерий значения	0,895

Вывод: Нет оснований отвергать гипотезу H_0, распределение можно считать нормальным

Рисунок 2.8 – Критерий типа Колмогорова – Смирнова

Критерий Фроцини:

zi	F(zi)	
-2,3729	0,008824464	0,003824464
-2,15738	0,015488209	0,000488209
-1,89552	0,029011742	0,004011742
-1,83308	0,033395479	0,001604521
-1,74244	0,040716094	0,004283906
-1,67194	0,04726842	0,00773158
-1,64374	0,050115296	0,014884704
-1,62762	0,051802469	0,023197531
-1,58734	0,056218148	0,028781852
-1,42821	0,076615728	0,018384272
-1,17643	0,11971231	0,01471231

Статистика Фроцини	0,16147342
Критическое значение	0,284

Вывод: Нет оснований отвергать гипотезу H_0, распределение можно считать нормальным

Рисунок 2.9 – Критерий типа Колмогорова – Смирнова

Вывод

В ходе выполнения работы была проведена оценка закона распределения генеральной совокупности на основе анализа выборочных данных. Использовались методы описательной статистики, графические инструменты, такие как гистограмма и график плотности распределения, а также статистические критерии согласия (например, критерий Колмогорова-Смирнова или Пирсона). В результате удалось выявить, что эмпирическое распределение выборки соответствует или не соответствует предполагаемому теоретическому распределению (например, нормальному, показательному, равномерному и т.д.).

Полученные результаты позволяют сделать вывод о характере распределения генеральной совокупности, что важно для дальнейшего статистического анализа, прогнозирования и принятия решений на основе данных. Работа подтвердила важность корректного выбора и применения методов оценки распределения, а также необходимость учёта ограничений, связанных с объёмом и репрезентативностью выборки.